

OVERVIEW DAN KONTEKS PROYEK

Dokumen ini adalah panduan teknis lengkap yang ditujukan kepada seluruh anggota tim A5 Tim 10 dalam mengembangkan sistem Smart Helpdesk Chatbot untuk PT. Indonesia Epson Industry. Baca seluruh bagian yang relevan dengan peran Anda sebelum mulai mengerjakan task.

Latar Belakang & Masalah yang Diselesaikan

PT. Indonesia Epson Industry adalah perusahaan manufaktur printer besar. Saat ini, proses helpdesk internal mereka masih manual — laporan masalah ditulis di kertas (Problem Report Form) atau email. Akibatnya:

- Tidak ada sistem terpusat untuk melacak masalah
- Teknisi baru kesulitan menemukan solusi untuk masalah yang sudah pernah terjadi
- Knowledge teknis bersifat personal, tidak tersharing ke seluruh tim
- Risiko stopline produksi akibat lambatnya penanganan masalah printer/hardware/firmware

Solusi yang Dibangun

Sebuah Smart Helpdesk Chatbot dengan arsitektur hybrid yang fleksibel. Frontend dan database berjalan di jaringan internal Epson, sedangkan AI engine dapat menggunakan model lokal, API eksternal, atau kombinasi keduanya tergantung kebutuhan. Chatbot ini:

- Menerima pertanyaan karyawan dalam bahasa alami (teks & gambar)
- Mencari jawaban dari knowledge base berisi laporan teknis manufaktur printer (sintetik)
- Menggunakan RAG (Retrieval-Augmented Generation) agar jawaban sesuai knowledge base
- AI engine bersifat modular: bisa Ollama lokal, API eksternal (OpenAI/Anthropic/Gemini), atau keduanya secara bersamaan dengan routing otomatis
- Data sensitif (chat logs, knowledge base, user data) tetap tersimpan di server internal

Stack Teknologi

Layer	Teknologi	Keterangan
Frontend	Next.js (React)	UI chatbot, dashboard admin, login page
Backend API	Express.js / Fastify + Node.js	REST API, business logic, orchestration

AI Engine (Lokal)	Ollama + Clawbot (opsional)	Model LLM lokal untuk pertanyaan standar — cepat, gratis, privat
AI Engine (Eksternal)	OpenAI API / Anthropic API / Gemini	Model cloud untuk pertanyaan kompleks yang butuh reasoning lebih dalam
AI Router	Logika routing di backend	Menentukan apakah query dikirim ke lokal atau API eksternal berdasarkan kompleksitas
Workflow Automation	n8n (opsional)	Automasi pipeline RAG, notifikasi email, scheduled KB update
RAG Pipeline	LangChain / LlamaIndex	Chunking, embedding, retrieval dokumen
Vector DB	ChromaDB / pgvector	Menyimpan embedding knowledge base
Database	PostgreSQL + Prisma ORM	Chat logs, tiket, user, knowledge entries
Deployment	Ubuntu Server (On-Premise)	Server internal PT. Epson

Catatan Penting: Clawbot dan n8n bersifat opsional. Arsitektur AI bersifat hybrid dan fleksibel — bisa memakai Ollama lokal saja, API eksternal saja, atau keduanya secara bersamaan. Pemilihan engine per-request ditentukan oleh AI Router di backend berdasarkan kompleksitas pertanyaan dan konfigurasi tim.

ARSITEKTUR SISTEM

Gambaran Arsitektur

Sistem terdiri dari 3 layer utama yang berkomunikasi melalui REST API JSON:

Layer	Komponen
Client Layer	Browser (Chrome/Edge) di intranet Epson → Next.js Frontend (Chat UI, Login, Dashboard Admin)
Application Layer	Express.js Backend API → AI Router → [Ollama Lokal API Eksternal Keduanya] → RAG Pipeline (Retrieval) → Response Generator → Escalation Handler
Data Layer	PostgreSQL (chat logs, tiket, users) + Vector DB (embeddings knowledge base) + Knowledge Base Files (PDF/JSON)

Alur Request Chatbot (End-to-End)

Berikut alur lengkap dari saat pengguna mengirim pesan hingga mendapat jawaban:

#	Step	Detail
1	User Input	Karyawan mengetik pertanyaan (teks) atau upload gambar defect printer via browser
2	POST /api/chat	Frontend mengirim JSON payload ke backend: { sessionId, userId, message, imageBase64? }
3	AI Router	Backend menentukan engine mana yang dipakai: Ollama lokal (pertanyaan sederhana/standar) atau API eksternal (pertanyaan kompleks/multimodal)
4	Query Embedding	Pertanyaan diubah menjadi vector embedding menggunakan model embedding lokal
5	Vector Search	Embedding dibandingkan dengan vector database (ChromaDB) untuk mencari dokumen paling relevan
6	Context Injection	Top-K dokumen relevan dimasukkan ke prompt sebagai context (RAG)
7	LLM Generation	Engine terpilih (Ollama atau API eksternal) generate jawaban berdasarkan context + pertanyaan asli
8	Response Check	Jika confidence rendah / jawaban tidak ditemukan → trigger escalation
9	Log & Store	Percakapan disimpan ke PostgreSQL (chat_logs table)
10	Return Response	Backend mengirim JSON response ke frontend → ditampilkan di chat UI

Strategi Hybrid AI Routing

Sistem menggunakan AI Router yang secara otomatis memilih engine berdasarkan karakteristik pertanyaan. Tidak ada kewajiban full on-premise — keputusan ada di tangan tim berdasarkan kebutuhan dan budget.

Tipe Pertanyaan	Engine yang Dipilih	Contoh	Alasan
Sederhana & ada di KB	Ollama Lokal (llama3.2)	Cara ganti tinta, error E-01	Cepat, gratis, privat — cukup untuk pertanyaan standar
Kompleks / reasoning dalam	API Eksternal (GPT-4o / Gemini)	Analisis penyebab akar masalah multi-faktor	Model lokal kurang kemampuan reasoning, butuh model besar
Analisis gambar (defect foto)	API Eksternal multimodal	Upload foto garis pada print	Model lokal (LLaVA) terbatas; GPT-4o Vision lebih akurat
Laporan analitik & summary	API Eksternal	Generate rangkuman top-issues mingguan	Butuh kemampuan summarization berkualitas tinggi
Fallback jika API down	Ollama Lokal	Semua tipe	Lokal selalu tersedia meski tidak ada internet

Logika Routing (Pseudocode)

```
// ai-engine/src/router.js
// Routing logic: tentukan engine berdasarkan karakteristik query

function selectEngine(query, hasImage, complexityScore) {
  // Selalu pakai lokal dulu jika sederhana dan tidak ada gambar
  if (!hasImage && complexityScore < 0.5) {
    return 'ollama-local'; // Murah, cepat, privat
  }

  // Gambar wajib pakai API eksternal multimodal
  if (hasImage) {
    return 'openai-gpt4o-vision'; // Atau gemini-pro-vision
  }

  // Pertanyaan kompleks (multi-step reasoning, analisis mendalam)
  if (complexityScore >= 0.5) {
    return 'openai-gpt4o-mini'; // Terjangkau tapi lebih pintar dari lokal
    // Atau: 'anthropic-claude-haiku' untuk alternatif yang lebih hemat
  }

  return 'ollama-local'; // Default fallback
}

// complexityScore dihitung dari: panjang pertanyaan, jumlah entitas,
// apakah mengandung kata "analisis", "kenapa", "bandingkan", "rekomendasi", dll.
```

Perbandingan Pilihan Engine

Engine	Biaya	Kecepatan	Kualitas	Kapan Pakai
Ollama (Lokal)	Gratis setelah setup	Tergantung GPU/CPU	Cukup untuk FAQ	Pertanyaan standar, fallback, dev/testing
GPT-4o-mini	~\$0.15/1M token input	Cepat (~2-4 detik)	Sangat Baik	Pertanyaan kompleks, reasoning mendalam
GPT-4o	~\$2.5/1M token input	Sedang (~3-6 detik)	Terbaik	Analisis gambar defect, kasus kritis
Claude Haiku	~\$0.25/1M token input	Sangat Cepat	Baik	Alternatif hemat GPT-4o-mini
Gemini Flash	~\$0.075/1M token	Sangat Cepat	Baik	Volume tinggi, biaya minimum

Rekomendasi: Mulai dengan Ollama untuk semua query di fase MVP. Setelah sistem stabil, aktifkan hybrid routing untuk pertanyaan yang memang membutuhkan model lebih besar. Budget API eksternal bisa dikendalikan dengan membatasi routing hanya pada query dengan complexityScore tinggi.